

Московский государственный университет имени М.В.Ломоносова Факультет вычислительной математики и кибернетики

## Трифонов Владислав Дмитриевич

# Отчет по заданию 1: Многопоточная реализация солвера СС для СЛАУ с разреженной матрицей, заданной в формате ELL

Курс "Параллельные вычисления" (1 курс магистратуры ВМК)

группа 528, дата подачи 13.10.2019

## Содержание

1	Опи	исание задания и программной реализации	3
	1.1	Краткое описание задания	3
	1.2	Краткое описание программной реализации	3
		1.2.1 Сборка	3
		1.2.2 Запуск	4
		1.2.3 Реализация	4
2	Исс	ледование производительности	6
	2.1	Характеристики вычислительной системы	6
		2.1.1 Компиляция	6
	2.2	Результаты измерений производительности	6
3	Ана	ализ полученных результатов	11
	3.1	Процент от пика	11
	3.2	Процент от достижимой производительности	13
4	Зак	лючение	17

## 1 Описание задания и программной реализации

#### 1.1 Краткое описание задания

В качестве задания 1 по курсу "Параллельные вычисления" предлагалось реализовать численное решение СЛАУ с разреженной матрицей, заданной в формате ELLPACK, методом сопряженных градиентов с предобуславливателем Якоби. Для этого требовалось:

- ullet реализовать генератор матрицы с диагональным преобладанием для расчетной области, представленной трехмерной декартовой решеткой заданного размера Nx, Ny, Nz
- выполнить последовательные реализации операций dot, axpby, SpMV, а также вспомогательные функции для работы с векторами
- реализовать предложенный солвер на основе данных операций
- выполнить многопоточные реализации данных операций с помощью библиотеки OpenMP
- реализовать многопоточный солвер
- реализовать проверочные вызовы последовательных и многопоточных реализаций для ручной проверки и оценки времени работы алгоритма
- исследовать эффективность реализованных алгоритмов

## 1.2 Краткое описание программной реализации

Реализация была выполнена на языке С.

#### **1.2.1** Сборка

Сборка выполняется с помощью Makefile. Компилятор и его параметры задаются в переменных Makefile CXX, CXXFLAGS (компилятор по-умолчанию – gcc). Скомпилированная программа находится по пути ./build/bin/main.

#### 1.2.2 Запуск

Параметры запуска можно узнать с помощью команды:

# ./build/bin/main --help

Пример запуска реализованных солверов с предварительной проверкой операций при размере сетки 5x5x5, 2 потоках, максимальном числе итераций 6, параметром eps=0.1, усреднением по 3 запускам:

# ./build/bin/main --qa --nx=5 --ny=5 --nz=5 --nt=2 --maxit=6 --tol=0.1 --nseeds=3

#### 1.2.3 Реализация

Для работы с матрицами в формате ELLPACK был реализован модуль  $ell\_utils.c$ , в нем содержатся функции:

- generate\_ELL\_3D\_DECART генерация случайной матрицы с диагональным преобладанием для трехмерной декартовой решетки заданных размеров
- delete ELL корректное освобождение выделенной памяти

Для работы с векторами был реализован модуль  $vector\_utils.c$ , в нем содержатся функции:

- create\_uninit\_Vector создание вектора заданной размерности без его инициализации
- create\_const\_Vector создание вектора заданной размерности с константной инициализацией
- $\bullet$  create\_cosine\_Vector создание вектора заданной размерности с инициализацией  $x_i = \cos(i*i)$
- $\bullet$ create\_sin\_Vector создание вектора заданной размерности с инициализацией  $x_i = sin(i*i)$
- сору Vector создание копии вектора

- copy\_from\_Vector\_to\_Vector копирование значений одного вектора в другой. Векторы должны быть одинаковых размеров
- compute sum подсчет суммы компонент вектора
- compute L2 norm подсчет L2 нормы
- compute\_L1\_norm подсчет L1 нормы
- compute Linf norm подсчет Linf нормы
- delete Vector корректное освобождение выделенной памяти

Базовые операции работы с векторами и матрицами выполнены в модуле ops utils.c:

- dot скалярное произведение двух векторов
- $\bullet$  axpby\_store операция  $r\vec{e}s = a * \vec{x} + b * \vec{y}$ , вектор результат должен быть указан
- ахрby аналогичная операция, для результата аллоцируется новая память
- SpMV\_store операция умножения разреженной матрицы на вектор, вектор результат должен быть указан
- SpMV аналогичная операция, для результата аллоцируется новая память
- inv\_diag\_SpMV\_store операция умножения обратной диагональной части разреженной матрицы на вектор, вектор результат должен быть указан
- inv\_diag\_SpMV аналогичная операция, для результата аллоцируется новая память

Аналогичные многопоточные операции реализованы в модуле  $omp\_ops\_utils.c.$ 

В модулях solver.c и omp\_solver.c реализованы функции solve и omp\_solve для решения СЛАУ с разреженной матрицей, заданной правой частью, начальным приближением, параметром eps и максимальным числом итераций.

В модуле main производится парсинг аргументов командной строки и использование приведенных функций.

## 2 Исследование производительности

#### 2.1 Характеристики вычислительной системы

Исследование было выполнено на ПК с 4-х ядерным CPU Intel i5-3570K, работающим на частоте 4.1 GHz, с памятью 4\*4Gb DDR3-1600MHz, работающей в двухканальном режиме. Пиковая производительность 131,2 GFLOPS, пиковая пропускная способность памяти 12.8\*2 = 25.6 Gb/s. OC – Ubuntu 16.04.

#### 2.1.1 Компиляция

Компиляция проводилась с помощью компилятора *gcc* 5.4.0 с флагами -g -Wall -O3 -Werror -Wl,-z,defs -Wextra -fopenmp.

### 2.2 Результаты измерений производительности

При проведении экспериментов проводилось 3 запуска, далее время усреднялось (--nseeds=3). В многопоточном варианте использовалось 2 и 4 потока(--nt=2, --nt=4). Параметр eps = 0.1, maxit = 20 (--tol=0.1 --maxit=20).

Посчитаем количество FLOP для каждой из операций в зависимости от размера N:

- $\bullet$  FLOP(dot) = N + (N-1) = 2N-1, N умножений и N-1 сложение
- FLOP(axpby) = 2N + 1N = 3N, 2N умножений и N сложений
- FLOP(SpMV) = (m+m-1)\*N = 13N, где m количество ненулевых элементов матрицы в строке, в предложенной декартовой сетке m=7
- $FLOP(inv\_diag\_SpMV) = 2N, N$  умножений и N делений
- $FLOP(solver) = FLOP(SpMV) + FLOP(axpby) + iter\_num*$  \*  $(FLOP(inv\_diag\_SpMV) + FLOP(dot) + FLOP(axpby) + FLOP(SpMV) + FLOP(dot) + 1 + 2*FLOP(axpby)) = FLOP(SpMV) + FLOP(axpby) + iter\_num*$  \*  $(FLOP(inv\_diag\_SpMV) + 2*FLOP(dot) + 3*FLOP(axpby) + FLOP(SpMV) + + 1)) = 16N + iter\_num*(2N + 4N 2 + 9N + 13N + 1) = N(16 + iter\_num*28),$  где  $iter\_num$  количество проведенных итераций

Размер системы $(N)$	$10^{6}$	$10^{7}$	$5*10^{7}$	$7.5 * 10^7$
GFLOP	$2*10^{-3}$	$2*10^{-2}$	$1*10^{-1}$	$1.5*10^{-1}$
Время последовательной реализации	0.001	0.009	0.047	0.070
(в секундах) $(T_1)$	0.001	0.009	0.047	0.070
GFLOPS (последовательная версия)	2.0	2.22	2.12	2.14
Время многопоточной реализации,	0.001	0.008	0.039	0.058
<b>2</b> потока $(T_2)$	0.001	0.000	0.059	0.036
GFLOPS (2 потока)	2.0	2.5	2.56	2.59
Ускорение (2 потока) $(T_1/T_2)$	1.0	1.125	1.20	1.21
Время многопоточной реализации,	0.003	0.009	0.039	0.057
4 потока $(T_4)$	0.003	0.009	0.039	0.001
GFLOPS (4 потока)	0.67	2.22	2.56	2.63
Ускорение (4 потока) $(T_1/T_4)$	0.33	1.0	1.20	1.23
$O$ тносительное ускорение $(T_2/T_4)$	0.33	0.89	1.0	1.01

Таблица 1: Результаты производительности операции dot

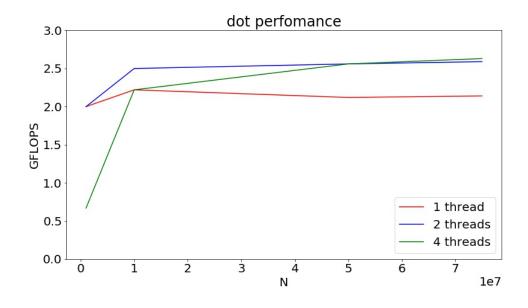


Рис. 1: Графики производительности операции dot

Pазмер системы $(N)$	$10^{6}$	$10^{7}$	$5*10^{7}$	$7.5 * 10^7$
GFLOP	$3*10^{-3}$	$3*10^{-2}$	$1.5*10^{-1}$	$2.25*10^{-1}$
Время последовательной реализации	0.003	0.027	0.135	0.204
(в секундах) $(T_1)$	0.003	0.021	0.133	0.204
GFLOPS (последовательная версия)	1.0	1.11	1.11	1.10
Время многопоточной реализации,	0.001	0.019	0.084	0.140
${f 2}$ потока $(T_2)$	0.001	0.019	0.004	0.140
GFLOPS (2 потока)	3.0	1.58	1.78	1.61
$oldsymbol{V}$ скорение (2 nomoкa) $(T_1/T_2)$	3.0	1.42	1.61	1.46
Время многопоточной реализации,	0.002	0.017	0.070	0.101
$4$ потока $(T_4)$	0.002	0.017	0.070	0.101
GFLOPS (4 потока)	2.0	1.76	2.14	2.23
Ускорение (4 потока) $(T_1/T_4)$	1.5	1.59	1.93	2.0
Относительное ускорение $(T_2/T_4)$	0.5	1.12	1.2	1.39

Таблица 2: Результаты производительности операции ахрbу

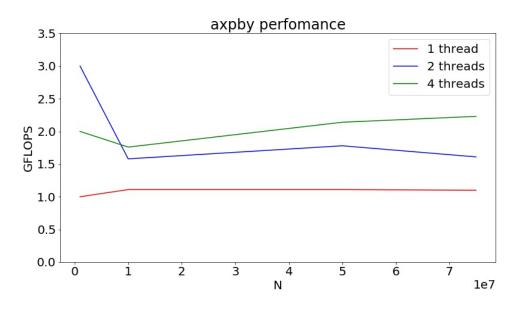


Рис. 2: Графики производительности операции ахрbу

ho Размер системы $(N)$	$10^{6}$	$10^{7}$	$5*10^{7}$	$7.5 * 10^{7}$
GFLOP	$1.6*10^{-2}$	$1.6 * 10^{-1}$	$8*10^{-1}$	1.2
Время последовательной реализации	0.009	0.107	0.535	0.807
(в секундах) $(T_1)$	0.009	0.107	0.555	0.807
GFLOPS (последовательная версия)	1.77	1.49	1.49	1.49
Время многопоточной реализации,	0.007	0.076	0.369	0.552
$2$ потока $(T_2)$	0.007	0.070	0.509	0.002
GFLOPS (2 потока)	2.28	2.10	2.17	2.17
Ускорение (2 потока) $(T_1/T_2)$	1.28	1.4	1.45	1.46
Время многопоточной реализации,	0.008	0.075	0.341	0.514
<b>4</b> потока $(T_4)$	0.008	0.075	0.541	0.514
GFLOPS (4 потока)	2	2.13	2.35	2.33
Ускорение (4 потока) $(T_1/T_4)$	1.125	1.43	1.57	1.57
Относительное ускорение $(T_2/T_4)$	0.875	1.01	1.08	1.07

Таблица 3: Результаты производительности операции SpMV

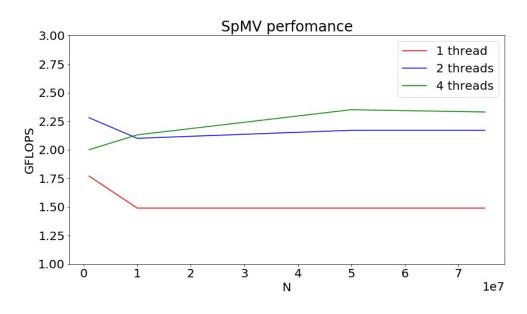


Рис. 3: Графики производительности операции SpMV

Pазмер системы $(N)$	$10^{6}$	$10^{7}$	$5*10^{7}$	$7.5 * 10^7$
Количество итераций	7	8	9	9
GFLOP	$2.12*10^{-1}$	2.40	$1.34 * 10^{1}$	$2.01*10^{1}$
Время последовательной реализации	0.161	1.963	10.719	15.925
(в секундах) $(T_1)$	0.101	1.905	10.719	10.920
GFLOPS (последовательная версия)	1.32	1.22	1.25	1.26
Время многопоточной реализации,	0.131	1.531	8.492	12.760
<b>2</b> потока ( <i>T</i> <sub>2</sub> )	0.131	1.001	0.402	12.700
GFLOPS (2 потока)	1.62	1.57	1.58	1.57
Ускорение (2 потока) $(T_1/T_2)$	1.23	1.28	1.26	1.25
Время многопоточной реализации,	0.139	1.496	8.151	12.331
4 потока $(T_4)$	0.133	1.430	0.101	12.551
GFLOPS (4 потока)	1.52	1.6	1.64	1.63
Ускорение (4 потока) $(T_1/T_4)$	1.16	1.31	1.31	1.29
$O$ тносительное ускорение $(T_2/T_4)$	0.94	1.02	1.04	1.03

Таблица 4: Результаты производительности солвера

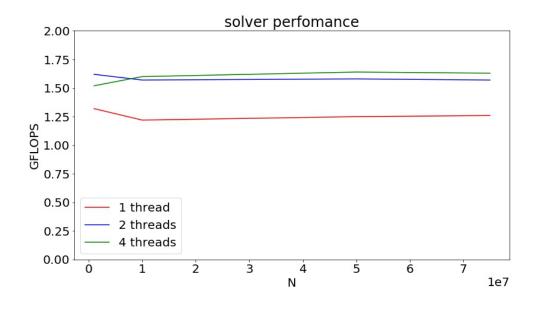


Рис. 4: Графики производительности солвера

## 3 Анализ полученных результатов

Пиковая производительность TPP=131,2 GFLOPS, пиковая пропускная способность памяти BW=25.6 Gb/s. На одно ядро  $TPP_p=32.8$  GFLOPS.

## 3.1 Процент от пика

Размер системы $(N)$	$10^{6}$	$10^{7}$	$5*10^{7}$	$7.5 * 10^7$
GFLOPS	2.0	2.22	2.12	2.14
(последовательная версия)	2.0	2.22	2.12	2.14
Процент от пика	6.1%	6.77%	6.46%	6.5%
$(GFLOPS/TPP_p)$	0.170	0.7770	0.4070	0.570
GFLOPS (2 потока)	2.0	2.5	2.56	2.59
Процент от пика (2 потока)	3.05%	3.81%	3.9%	3.95%
$(GFLOPS/(2*TPP_p))$	3.0370	3.01/0	3.970	3.9370
GFLOPS (4 потока)	0.67	2.22	2.56	2.63
Процент от пика (4 потока)	0.51%	1.69%	1.95%	2.00%
$(GFLOPS/(4*TPP_p))$	0.51/0	1.09/0	1.99/0	2.00/0

Таблица 5: Анализ достигаемой производительности для операции dot

Размер системы $(N)$	$10^{6}$	$10^{7}$	$5*10^{7}$	$7.5 * 10^7$
GFLOPS	1.0	1.11	1.11	1.10
(последовательная версия)	1.0	1.11	1.11	1.10
Процент от пика	3.04%	3.38%	3.38%	3.35%
$(GFLOPS/TPP_p)$	3.0470	3.3670	3.3670	<b>3.33</b> 70
GFLOPS (2 потока)	3.0	1.58	1.78	1.61
Процент от пика (2 потока)	4.57%	2.4%	2.71%	2.45%
$(GFLOPS/(2*TPP_p))$	4.57 /0	2.4/0	2.71/0	2.49/0
GFLOPS (4 потока)	2.0	1.76	2.14	2.23
Процент от пика (4 потока)	1.52%	1.34%	1.63%	1.70%
$(GFLOPS/(4*TPP_p))$	1.02/0	1.04/0	0 1.03/0	1.7070

Таблица 6: Анализ достигаемой производительности для операции ахрbу

Размер системы $(N)$	$10^{6}$	$10^{7}$	$5*10^{7}$	$7.5*10^{7}$
GFLOPS	1.77	1.49	1.49	1.49
(последовательная версия)	1.77	1.43	1.43	1.49
Процент от пика	5.40%	4.54%	4.54%	4.54%
$(GFLOPS/TPP_p)$	3.4070	4.04/0	4.04/0	4.94/0
GFLOPS (2 потока)	2.28	2.10	2.17	2.17
Процент от пика (2 потока)	3.47%	3.20%	3.30%	3.30%
$(GFLOPS/(2*TPP_p))$	3.41/0	3.2070	3.3070	3.3070
GFLOPS (4 потока)	2	2.13	2.35	2.33
Процент от пика (4 потока)	1.52%	1.62%	1.79%	1.77%
$(GFLOPS/(4*TPP_p))$	1.02/0	1.02/0	1.79/0	1.17/0

Таблица 7: Анализ достигаемой производительности для операции SpMV

Размер системы $(N)$	$10^{6}$	$10^{7}$	$5*10^{7}$	$7.5 * 10^7$
GFLOPS	1.32	1.22	1.25	1.26
(последовательная версия)	1.02	1.22	1.20	1.20
Процент от пика	4.02%	3.72%	3.81%	3.84%
$(GFLOPS/TPP_p)$	4.02/0	3.12/0	3.01/0	<b>3.04</b> /0
GFLOPS (2 потока)	1.62	1.57	1.58	1.57
Процент от пика (2 потока)	2.47%	2.39%	2.41%	2.39%
$(GFLOPS/(2*TPP_p))$	2.41/0	2.39/0	2.41/0	2.39/0
GFLOPS (4 потока)	1.52	1.6	1.64	1.63
Процент от пика (4 потока)	1.16%	1.22%	1 9507	1.24%
$(GFLOPS/(4*TPP_p))$	1.1070	1.4470	$\% \mid 1.25\%$	1.4470

Таблица 8: Анализ достигаемой производительности солвера

#### 3.2 Процент от достижимой производительности

Для оценки вычислительной интенсивности посчитаем количество обращений в памяти для каждой из операций, учитывая что sizeof(double) = 8 байт, sizeof(int) = 4 байт:

- DATA(dot) = 8 \* 2N = 16N байт, чтение компонент 2 векторов
- DATA(axpby) = 8 \* 3N = 24N байт, 2 чтения и 1 запись
- DATA(SpMV) = N(4\*m+8\*m) + N + N = 86N байт, чтение m номеров столбцов и значений матрицы, запись вектора из N чисел и чтение вектора из N чисел (считаем, что чтение происходит один раз)
- $DATA(inv\_diag\_SpMV) = 8*3N = 24N$  байт, 2 чтения и 1 запись
- $DATA(solver) = DATA(SpMV) + DATA(axpby) + iter\_num*$  \*  $(DATA(inv\_diag\_SpMV) + DATA(dot) + DATA(axpby) + 1 + DATA(SpMV) + DATA(dot) + 2 + 2 * DATA(axpby)) = DATA(SpMV) + DATA(axpby) + iter\_num*$  \*  $(DATA(inv\_diag\_SpMV) + 2 * DATA(dot) + 3 * DATA(axpby) + DATA(SpMV) + 2 * DATA(sphy) + D$

Теперь вычислим значение вычислительной интенсивности:

• 
$$AI(dot) = \frac{2N-1}{16N} = \frac{1}{8} = 0.125 \text{ FLOP}/байт}$$

• 
$$AI(axpby) = \frac{3N}{24N} = \frac{1}{8} = 0.125 \text{ FLOP/байт}$$

• 
$$AI(SpMV) = \frac{13N}{84N} = 0.15 \; \mathrm{FLOP}/\mathrm{байт}$$

• 
$$AI(solver) = \frac{16 + 28*iter\_num}{110 + 214*iter\_num}$$
 FLOP/байт

Теоретически достижимая производительность TBP = min(TPP, BW \* AI):

• 
$$TBP(dot) = 25.6 * \frac{1}{8} = 3.2 \text{ GFLOPS}$$

• 
$$TBP(axpby) = 25.6 * \frac{1}{8} = 3.2 \text{ GFLOPS}$$

• 
$$TBP(SpMV) = 25.6 * \frac{13}{84} = 3.96 \text{ GFLOPS}$$

• 
$$TBP(solver) = 25.6 * \frac{16 + 28 * iter\_num}{110 + 214 * iter\_num}$$
 GFLOPS

$\mathbb{P}$ азмер системы $(N)$	$10^{6}$	$10^{7}$	$5*10^{7}$	$7.5 * 10^7$
TBР в GFLOPS	3.2	3.2	3.2	3.2
GFLOPS	2.0	2.22	2.12	2.14
(последовательная версия)		2.22	2.12	2.14
Процент от пика	62.5%	69.35%	66.25%	66.85%
(GFLOPS/TBP)		09.5570	00.2570	00.8570
GFLOPS (2 потока)	2.0	2.5	2.56	2.59
Процент от пика (2 потока)	62.5%	78.1%	80.0%	80.94%
(GFLOPS/TBP)	02.570	70.170	00.070	00.9470
GFLOPS (4 потока)	0.67	2.22	2.56	2.63
Процент от пика (4 потока)	20.94%	69.35%	80.0%	82.2%
(GFLOPS/TBP)	20.34/0	09.00/0	70   80.0%	02.270

Таблица 9: Анализ достигаемой производительности операции dot с учетом пропускной способности памяти

Размер системы $(N)$	$10^{6}$	$10^{7}$	$5*10^{7}$	$7.5 * 10^7$
TBР в GFLOPS	3.2	3.2	3.2	3.2
GFLOPS	1.0	1.11	1.11	1.10
(последовательная версия)		1.11	1.11	1.10
Процент от пика	31.25%	34.68%	34.68%	34.37%
(GFLOPS/TBP)	31.2370	<b>34.0</b> 670	34.0070	34.3170
GFLOPS (2 потока)	3.0	1.58	1.78	1.61
Процент от пика (2 потока)	93.1%	49.37%	55.62%	50.31%
(GFLOPS/TBP)	95.170	49.31/0	33.02/0	30.3170
GFLOPS (4 потока)	2.0	1.76	2.14	2.23
Процент от пика (4 потока)	62.5%	55.5%	66.87%	69.68%
(GFLOPS/TBP)	02.070	00.070	5.570 00.8770	03.0070

Таблица 10: Анализ достигаемой производительности операции axpby с учетом пропускной способности памяти

$\mathbb{P}$ азмер системы $(N)$	$10^{6}$	$10^{7}$	$5*10^{7}$	$7.5 * 10^7$
TBР в GFLOPS	3.96	3.96	3.96	3.96
GFLOPS	1.77	1.49	1.49	1.49
(последовательная версия)		1.43	1.43	1.49
Процент от пика	44.69%	37.62%	37.62%	37.62%
(GFLOPS/TBP)	44.09/0	31.0270	31.02/0	37.02/0
GFLOPS (2 потока)	2.28	2.10	2.17	2.17
Процент от пика (2 потока)	57.57%	53.03%	54.79%	54.79%
(GFLOPS/TBP)	37.3770	00.0070	34.79/0	34.79/0
GFLOPS (4 потока)	2.0	2.13	2.35	2.33
Процент от пика (4 потока)	50.50%	53.79%	59.34%	58.83%
(GFLOPS/TBP)	30.30/0	53.79%	9/0   09.04/0	JG.GJ/0

Таблица 11: Анализ достигаемой производительности операции SpMV с учетом пропускной способности памяти

$\Gamma$ Размер системы $(N)$	$10^{6}$	$10^{7}$	$5*10^{7}$	$7.5 * 10^7$
Количество итераций	7	8	9	9
TBР в GFLOPS	3.37	3.37	3.37	3.37
GFLOPS	1.32	1.22	1.25	1.26
(последовательная версия)				
Процент от пика	39.17%	36.2%	37.09%	37.39%
(GFLOPS/TBP)				
GFLOPS (2 потока)	1.62	1.57	1.58	1.57
Процент от пика (2 потока)	48.07%	46.59%	$\boxed{46.88\%}$	46.59%
(GFLOPS/TBP)				
GFLOPS (4 потока)	1.52	1.6	1.64	1.63
Процент от пика (4 потока)	45.10%	47.48%	48.66%	48.37%
(GFLOPS/TBP)				

Таблица 12: Анализ достигаемой производительности солвера с учетом пропускной способности памяти

## 4 Заключение

В результате практического задания была выполнена последовательная и многопоточная реализация солвера СЛАУ с разреженной матрицей. В ряде экспериментов было установлено, что, несмотря на высокую теоретическую пиковую производительность процессора, фактически достигаемая производительность реализованных алгоритмов сильно зависит от пропускной способности памяти, что ограничивает эффективность многопоточной версии солвера.